

Associação de long non-coding RNAs a doenças

Introdução

Os RNAs não codificantes longos (lncRNAs) são uma categoria importante de RNAs não codificantes (ncRNAs) que variam de 200 nucleotídeos a vários quilobases de comprimento, com pouca ou nenhuma capacidade de codificação de proteínas. Evidências crescentes destacaram os papéis críticos dos lncRNAs no desenvolvimento e progressão de muitas doenças.

Tendo em vista a participação de lncRNAs em um vasto repertório de processos biológicos, mutações e desregulações desses RNAs estão associadas ao desenvolvimento e progressão de diversas doenças humanas complexas. Estas incluem diabetes [1], AIDS [2], doenças cardiovasculares [3], doenças neurológicas [4] e diversos tipos de cânceres [5].

Sendo assim, a identificação de lncRNAs pode contribuir significativamente para a compreensão dos mecanismos moleculares de doenças associadas. Isso possibilita a descoberta de lncRNAs como potenciais biomarcadores para diagnóstico, tratamento e prognóstico de doenças, bem como alvos terapêuticos em potencial para a descoberta de fármacos [6]. Como exemplo, MALAT1 (Metastasis-Associated Lung Adenocarcinoma Transcript 1) foi reportado como um biomarcador para detecção de vários cânceres, e sua supressão em células tumorais reduz metástase, proliferação e migração, sugerindo seu potencial terapêutico [7].

Nos últimos anos, um número crescente de abordagens biotecnológicas têm sido utilizado para identificação e detecção de lncRNAs. Estes métodos incluem microarray, tecnologias de sequenciamento de transcriptoma (RNA-seq), reação em cadeia da polimerase de transcrição reversa em tempo real (qRT-PCR), northern blot, entre outros. No entanto, existem algumas dificuldades envolvidas na realização dessas técnicas, como alto custo, procedimento operacional complexo e certo dano ao corpo humano durante o processo experimental.

Métodos *in silico* baseados em aprendizado de máquina oferecem uma abordagem viável para a predição de associações entre lncRNAs e doenças de forma eficiente e rápida. Isso se deve ao fato de que o uso de métodos computacionais contribui para a redução de tempo e custos experimentais em comparação aos métodos tradicionais de pesquisa, permitindo análise simultânea e de grande escala. Diante deste cenário, o desenvolvimento de modelos baseados em inteligência artificial para a previsão de doenças a partir de dados de lncRNAs revela-se altamente promissor.

A predição associações lncRNA-doenças permite identificar novos alvos terapêuticos, possibilitando o desenvolvimento de tratamentos mais eficazes. Esta abordagem também viabiliza a detecção de biomarcadores para prognóstico, diagnóstico e monitoramento das condições clínicas. Além disso, a previsão destas interações torna possível a formulação de novas abordagens para prevenção de doenças. Tais contribuições podem representar um avanço significativo da medicina personalizada, proporcionando estratégias mais eficientes e direcionadas.

Descrição da Atividade

A predição de doenças a partir de lncRNAs representa um problema de classificação multirrótulo, dado que um mesmo RNA pode estar simultaneamente associado a mais de uma doença. Desta forma, o objetivo desta atividade é investigar e aplicar métodos de classificação multirrótulo utilizando Redes Neurais Artificiais na predição de doenças associadas a RNAs longos não codificantes (lncRNAs).

Na literatura de Aprendizado de Máquina, problemas de classificação convencionais são chamados de problemas monorrótulo. Nesses problemas, um classificador é treinado em um conjunto de exemplos que estão associados com uma única classe l de um conjunto de classes disjuntas L , onde $|L| > 1$. Se $|L| = 2$, então o problema é denominado problema de classificação binária, e se $|L| > 2$, o problema é chamado problema de classificação multi-classe. Em uma classificação multirrótulo, os exemplos estão associados a um conjunto de classes $Y \subseteq L$, sendo $|Y| > 1$ [8].

Como conjuntos de dados, devem ser utilizadas associações entre lncRNAs e doenças disponíveis no repositório lncRNADisease v3.0 (<http://www.rnanut.net/lncrnadisease/>) [9]. A documentação deve ser lida, e lncRNAs de humanos devem ser baixados, juntamente com as doenças associadas.

Fiquem atentos, pois as sequências dos lncRNAs podem não estar disponíveis no lncRNADisease, mas apenas seus IDs do Genban. Nesse caso, pode ser utilizado o pacote Bio.Entrez da biblioteca Biopython, o qual fornece código para acessar o NCBI pela Internet e recuperar sequências a partir de seu ID.

Uma vez obtidas as sequências e correspondentes doenças, diversas ferramentas podem ser utilizadas para a extração de características das sequências de lncRNAs, características essas que serão utilizadas como atributos de entrada para os algoritmos de Aprendizado de Máquina. Entre as ferramentas que podem ser utilizadas estão:

- Pse-in-One: um servidor web para gerar modos abrangentes de pseudo componentes de sequências de DNA, RNA e proteínas - <http://bliulab.net/Pse-in-One2.0/home/>;
- MathFeature: permite a extração de diversos tipos de características - <https://github.com/Bonidia/MathFeature>;

Vocês podem escolher um único tipo de característica ou um conjunto de tipos. Isso fica a critério de vocês e faz parte do trabalho.

A escolha de qual rede neural utilizar, a escolha das doenças, o pré-processamento e formatação dos dados, e a análise exploratória fazem parte da atividade, e as decisões devem ser tomadas pelo grupo de desenvolvimento.

Tarefas

1. Montagem dos Dados: Construção do conjunto de dados como descrito acima;
2. Fazer um experimento utilizando uma estratégia adequada para divisão do conjunto de dados entre treino/validação/teste;
3. Pré-processamento: Aplicar qualquer estratégia de pré-processamento que considerarem necessária, como normalização, padronização ou seleção de atributos;
4. Construção do Modelo: Construir um modelo de classificação usando redes neurais artificiais. A escolha da rede neural fica a critério de vocês, mas deve ser justificada;

5. Avaliação de Desempenho: Avaliar o desempenho do modelo nas partições de teste utilizando a área abaixo da curva Precisão-Revocação [10].

Entregáveis

1. **Notebook Python no Google Colab:** Enviar um notebook (.ipynb) com o código bem documentado e instruções para reprodução;
2. **Relatório de Pesquisa:** Elaborar um relatório de 8 a 10 páginas no formato de artigo científico contendo as seções: Resumo, Introdução, Metodologia, Experimentos, Discussões, Conclusão;
3. **Vídeo:** vídeo de 10 minutos apresentando o problema e explicando a solução proposta com seus resultados. Fazer upload do vídeo no YouTube e marcar como não listado. Entregar um arquivo .txt com a url para o vídeo.

Templates de artigo para Overleaf e .docx.

Vocês devem seguir esses templates para a confecção do relatório de pesquisa:

- Overleaf: <https://www.overleaf.com/latex/templates/sbc-conferences-template/blbxwjwzdngr>
- Docx: <https://www.sbc.org.br/wp-content/uploads/2024/07/modelosparapublicaodeartigos.zip>

Referências

- [1] PASMANT, E.; SABBAGH, A.; VIDAUD, M.; et al. ANRIL, a long, noncoding RNA, is an unexpected major hotspot in GWAS. *FASEB Journal*, v. 25, p. 444–448, 2011.
- [2] ZHANG, Q.; CHEN, C.-Y.; YEDAVALLI, V. S. R. K.; et al. NEAT1 long noncoding RNA and paraspeckle bodies modulate HIV-1 posttranscriptional expression. *Journal of Virology*, v. 87, p. 596–612, 2013.
- [3] CONGRAINS, A.; KAMIDE, K.; OGURA, R.; et al. Genetic variants at the 9p21 locus contribute to atherosclerosis through modulation of ANRIL and CDKN2A/B. *Atherosclerosis*, v. 220, p. 449–455, 2012.
- [4] JOHNSON, R. Long non-coding RNAs in Huntington's disease neurodegeneration. *Neurobiology of Disease*, v. 46, p. 245–254, 2012.
- [5] SPIZZO, R.; et al. Long non-coding RNAs and cancer: a new frontier of translational research? *Oncogene*, v. 31, p. 4577–4587, 2012.
- [6] YUAN, L. Long non-coding RNAs towards precision medicine in gastric cancer: early diagnosis, treatment, and drug resistance. *Molecular Cancer*, p. 1–22, 2020.
- [7] AMODIO, N. MALAT1: a druggable long non-coding RNA for targeted anti-cancer approaches. *Journal of Hematology & Oncology*, n. 11, p. 1–19, 2018.
- [8] TSOUMAKAS, G.; KATAKIS, I.; VLAHAVAS, I. P. Mining Multi-label Data. In: MAIMON, O.; ROKACH, L. (Ed.). *Data Mining and Knowledge Discovery Handbook*. 2. ed. p. 667–685, 2010.
- [9] Lin et al., LncRNADisease v3.0: an updated database of long non-coding RNA-associated diseases. *Nucleic Acids Res.* 2024 Jan 5;52(D1):D1365-D1369. doi: 10.1093/nar/gkad828.
- [10] Jesse Davis and Mark Goadrich. 2006. The relationship between Precision-Recall and ROC curves. In *Proceedings of the 23rd international conference on Machine learning (ICML '06)*. Association for Computing Machinery, New York, NY, USA, 233–240. <https://doi.org/10.1145/1143844.1143874>.